

Vybrané slajdy k přednášce z předmětu  
**NUMERICKÉ METODY** (12NME1, 12NMEA)  
na KFE FJFI ČVUT v Praze

## 2. Numerické metody lineární algebry

*Pracovní verze, 21. února 2024. Bude průběžně aktualizováno.*

### !!! TOTO NEJSOU SKRIPTA !!!

Tento dokument není náhradou přednášek, pouze doplňkem.  
Neobsahuje všechna vysvětlení a odvození. Nepokrývá veškerou  
náplň předmětu, jejíž zvládnutí je nutné ke složení zkoušky.

Primárním zdrojem informací jsou přednášky, účast na nich důrazně doporučuji.

Opravy a připomínky prosím na `pavel.vachal@fjfi.cvut.cz`

## Úlohy lineární algebry

---

$$\vec{x} = \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix}, \quad \mathbf{A} = \begin{pmatrix} a_{11} & a_{12} & \dots & a_{1n} \\ a_{21} & a_{22} & \dots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{m1} & a_{m2} & \dots & a_{mn} \end{pmatrix}$$

- Řešení soustav lineárních rovnic
  - Řešení soustav s regulární čtvercovou maticí a jednou nebo více pravými stranami
  - Výpočet inverzní matice  $\mathbf{A}^{-1}$
  - Výpočet determinantu matice:  $\det(\mathbf{A})$
  - Řešení lineárních soustav s jinými maticemi
    - \* Matice  $m \times n$  ( $m$  rovnic o  $n$  neznámých)
    - \* Singulární čtvercové matice
  - v určitém smyslu (jedno řešení + nulprostor, řešení ve smyslu nejmenších čtverců, ...)
- Hledání vlastních čísel a vlastních vektorů
  - Úplný problém
  - Částečný problém

## Vektorové a maticové normy

### Vektorová norma

- Musí splňovat 3 podmínky:

a)  $\|\vec{x}\| \geq 0, \quad \|\vec{x}\| = 0 \Leftrightarrow \vec{x} = \vec{0},$

b)  $\|\lambda \vec{x}\| = |\lambda| \|\vec{x}\|$

c)  $\|\vec{x} + \vec{y}\| \leq \|\vec{x}\| + \|\vec{y}\|$

- maximová

$$L_{\max}(\vec{x}) = \|\vec{x}\|_I = \max_i |x_i|$$

- součtová

$$L_1(\vec{x}) = \|\vec{x}\|_{II} = \sum_i |x_i|$$

- eukleidovská

$$L_2(\vec{x}) = \|\vec{x}\|_{III} = \sqrt{\sum_i x_i^2}$$

### Maticová norma ( $a_{ij} = a_{řád.,sl.}$ )

≡ vekt. norma matice, která navíc splňuje podmínku pro násobení matic:  $\forall \mathbf{A}, \forall \mathbf{B},$

d)  $\|\mathbf{A} \cdot \mathbf{B}\| \leq \|\mathbf{A}\| \|\mathbf{B}\|$

- řádková

$$\|\mathbf{A}\|_I = \max_i \sum_j |a_{ij}|$$

- sloupcová

$$\|\mathbf{A}\|_{II} = \max_j \sum_i |a_{ij}|$$

- eukleidovská

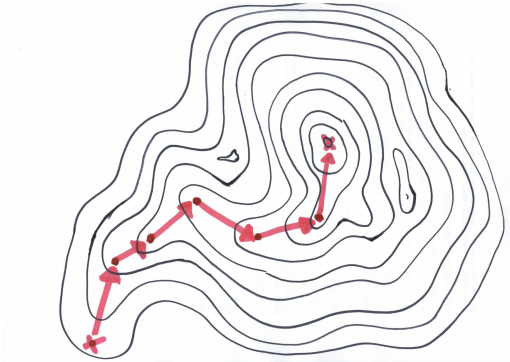
$$L_2(\mathbf{A}) = \|\mathbf{A}\|_{III} = \sqrt{\sum_i \sum_j a_{ij}^2}$$

- Každá z těchto maticových norem je **souhlasná** se stejně označenou vektorovou normou, tedy  $\forall \mathbf{A}, \forall \vec{x}, \quad \|\mathbf{A}\vec{x}\| \leq \|\mathbf{A}\| \|\vec{x}\|$

## Metody řešení soustavy lineárních rovnic $\mathbf{A}\vec{x} = \vec{b}$

---

- Přímé (finitní)
  - přímý běh (úprava na  $\Delta$  tvar) + zpětný běh
  - nebo úprava matice rovnou na diagonální tvar
- Iterační
  - postupné zpřesňování výsledku
- Minimalizací funkce  $f = |\mathbf{A}\vec{x} - \vec{b}|$  nebo  $f = \|\mathbf{A}\vec{x} - \vec{b}\|_{III}$ 
  - např. gradientními metodami



## Soustava s horní $\triangle$ maticí

---

$$\begin{pmatrix} u_{1,1} & u_{1,2} & u_{1,3} & \dots & u_{1,n-1} & u_{1,n} \\ 0 & u_{2,2} & u_{2,3} & \dots & u_{2,n-1} & u_{2,n} \\ 0 & 0 & u_{3,3} & \dots & u_{3,n-1} & u_{3,n} \\ \vdots & \vdots & \vdots & \ddots & \vdots & \vdots \\ 0 & 0 & 0 & \dots & u_{n-1,n-1} & u_{n-1,n} \\ 0 & 0 & 0 & \dots & 0 & u_{n,n} \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ x_3 \\ \vdots \\ x_{n-1} \\ x_n \end{pmatrix} = \begin{pmatrix} b_1 \\ b_2 \\ b_3 \\ \vdots \\ b_{n-1} \\ b_n \end{pmatrix}$$

## Soustava s horní $\Delta$ maticí

---

$$\begin{pmatrix} u_{1,1} & u_{1,2} & u_{1,3} & \cdots & u_{1,n-1} & u_{1,n} \\ 0 & u_{2,2} & u_{2,3} & \cdots & u_{2,n-1} & u_{2,n} \\ 0 & 0 & u_{3,3} & \cdots & u_{3,n-1} & u_{3,n} \\ \vdots & \vdots & \vdots & \ddots & \vdots & \vdots \\ 0 & 0 & 0 & \cdots & u_{n-1,n-1} & u_{n-1,n} \\ 0 & 0 & 0 & \cdots & 0 & u_{n,n} \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ x_3 \\ \vdots \\ x_{n-1} \\ x_n \end{pmatrix} = \begin{pmatrix} b_1 \\ b_2 \\ b_3 \\ \vdots \\ b_{n-1} \\ b_n \end{pmatrix}$$


---

### Zpětný běh:

---

- Předpokládejme, že  $u_{ii} \neq 0, \forall i$ . Postupujeme ve směru klesajícího indexu  $k$ :

$$\begin{aligned} x_n &= \frac{b_n}{u_{n,n}} \\ x_{n-1} &= \frac{b_{n-1} - u_{n-1,n} x_n}{u_{n-1,n-1}} \quad (\text{protože} \quad u_{n-1,n-1} x_{n-1} + u_{n-1,n} x_n = b_{n-1}) \\ &\vdots \\ x_k &= \frac{1}{u_{k,k}} \left( b_k - \sum_{j=k+1}^n u_{k,j} x_j \right) \quad \text{pro} \quad k = n-2, \dots, 1 \end{aligned}$$

## Gaussova eliminace

---

$$\begin{pmatrix} a_{1,1} & a_{1,2} & a_{1,3} & \dots & a_{1,n} \\ a_{2,1} & a_{2,2} & a_{2,3} & \dots & a_{2,n} \\ a_{3,1} & a_{3,2} & a_{3,3} & \dots & a_{3,n} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ a_{n,1} & a_{n,2} & a_{n,3} & \dots & a_{n,n} \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ x_3 \\ \vdots \\ x_n \end{pmatrix} = \begin{pmatrix} b_1 \\ b_2 \\ b_3 \\ \vdots \\ b_n \end{pmatrix}$$

Eliminace prvního sloupce:

$$\begin{aligned} a_{i,j}^{(1)} &= a_{i,j} - \frac{a_{i,1}}{a_{1,1}} a_{1,j}, \\ b_i^{(1)} &= b_i - \frac{a_{i,1}}{a_{1,1}} b_1 \end{aligned} \quad \rightarrow \quad \begin{pmatrix} a_{1,1} & a_{1,2} & a_{1,3} & \dots & a_{1,n} \\ 0 & a_{2,2}^{(1)} & a_{2,3}^{(1)} & \dots & a_{2,n}^{(1)} \\ 0 & a_{3,2}^{(1)} & a_{3,3}^{(1)} & \dots & a_{3,n}^{(1)} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & a_{n,2}^{(1)} & a_{n,3}^{(1)} & \dots & a_{n,n}^{(1)} \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ x_3 \\ \vdots \\ x_n \end{pmatrix} = \begin{pmatrix} b_1 \\ b_2^{(1)} \\ b_3^{(1)} \\ \vdots \\ b_n^{(1)} \end{pmatrix}$$

Maticově

$$\mathbf{A}\vec{x} = \vec{b} \quad \rightarrow \quad \mathbf{D}_1 \mathbf{A} \vec{x} = \mathbf{D}_1 \vec{b}, \quad \text{kde} \quad \mathbf{D}_1 = \begin{pmatrix} 1 & 0 & 0 & \dots & 0 \\ -\frac{a_{21}}{a_{11}} & 1 & 0 & \dots & 0 \\ -\frac{a_{31}}{a_{11}} & 0 & 1 & \dots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ -\frac{a_{n1}}{a_{11}} & 0 & 0 & \dots & 1 \end{pmatrix}$$

## Gauss-Jordanova eliminace

---

$$\begin{pmatrix} a_{1,1}^{(n)} & 0 & 0 & \dots & 0 \\ 0 & a_{2,2}^{(n)} & 0 & \dots & 0 \\ 0 & 0 & a_{1,1}^{(n)} & \dots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & \dots & a_{n,n}^{(n)} \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ x_3 \\ \vdots \\ x_n \end{pmatrix} = \begin{pmatrix} b_1^{(n)} \\ b_2^{(n)} \\ b_3^{(n)} \\ \vdots \\ b_n^{(n)} \end{pmatrix}$$



## LU metoda

$$\begin{pmatrix} a_{11} & a_{12} & a_{13} & \dots & a_{1n} \\ a_{21} & a_{22} & a_{23} & \dots & a_{2n} \\ a_{31} & a_{32} & a_{33} & \dots & a_{3n} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & a_{n3} & \dots & a_{nn} \end{pmatrix} = \begin{pmatrix} 1 & 0 & 0 & \dots & 0 \\ l_{21} & 1 & 0 & \dots & 0 \\ l_{31} & l_{32} & 1 & \dots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ l_{n1} & l_{n2} & l_{n3} & \dots & 1 \end{pmatrix} \cdot \begin{pmatrix} u_{11} & u_{12} & u_{13} & \dots & u_{1n} \\ 0 & u_{22} & u_{23} & \dots & u_{2n} \\ 0 & 0 & u_{33} & \dots & u_{3n} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & \dots & u_{nn} \end{pmatrix}$$

$$\mathbf{A}\vec{x} = \vec{b} \Leftrightarrow (\mathbf{LU})\vec{x} = \vec{b} \Leftrightarrow \mathbf{L} \overbrace{(\mathbf{U})\vec{x}}^{\text{ozn. } \vec{y}} = \vec{b} \Leftrightarrow \begin{cases} \mathbf{L}\vec{y} = \vec{b} \\ \mathbf{U}\vec{x} = \vec{y} \end{cases}$$

Odvození LU dekompozice  
z definice násobení matic:

$$a_{ij} = \begin{cases} u_{ij} + \sum_{k=1}^{i-1} l_{ik} u_{kj} & \text{pro } i \leq j, \text{ tedy nad diag.} \\ \sum_{k=1}^j l_{ik} u_{kj} = l_{ij} u_{jj} + \sum_{k=1}^{j-1} l_{ik} u_{kj} & \text{pro } i > j, \text{ tedy pod diag.} \end{cases}$$

⇒ **Croutův algoritmus:**

FOR J:=1 TO N DO BEGIN

FOR I:=1 TO J DO

$$u_{ij} = a_{ij} - \sum_{k=1}^{i-1} l_{ik} u_{kj}$$

*používá l z předchozích sloupců  
a u z předchozích řádků*

FOR I:=J+1 TO N DO

$$l_{ij} = \frac{1}{u_{jj}} \left( a_{ij} - \sum_{k=1}^{j-1} l_{ik} u_{kj} \right)$$

*používá l z předchozích sloupců a  
u z nad diagonální části sloupce*

END

## Iterativní zpřesnění řešení

---

► Odvození:

$$\mathbf{A}(\vec{x} + \vec{\delta x}) = (\vec{b} + \vec{\delta b}) \quad \Rightarrow \quad \left\{ \begin{array}{l} \bullet \quad \mathbf{A}\vec{\delta x} = \vec{\delta b} \\ \bullet \quad \mathbf{A}(\vec{x} + \vec{\delta x}) - \vec{b} = \vec{\delta b} \end{array} \right\} \quad \Rightarrow \quad \mathbf{A} \underbrace{\vec{\delta x}}_{\text{ozn. } (\vec{\delta x})^{(i)}} = \underbrace{\mathbf{A}(\vec{x} + \vec{\delta x}) - \vec{b}}_{\text{ozn. } \vec{x}^{(i)}}$$

► Postup:

Odhadneme přibližné řešení  $\mathbf{A}\vec{x}^{(0)} = \vec{b}$  a pak iterujeme

- Hledám  $(\vec{\delta x})^{(i)}$  tak, aby  $\mathbf{A}(\vec{\delta x})^{(i)} = \mathbf{A}\vec{x}^{(i)} - \vec{b}$
- $\vec{x}^{(i+1)} = \vec{x}^{(i)} - (\vec{\delta x})^{(i)}$
- $i = i + 1$

## Podmíněnost řešení soustavy lin. rovnic $\mathbf{A}\vec{x} = \vec{b}$

---

• Pro  $\Delta\mathbf{A} = \mathbf{0}$  :

$$\frac{\|\Delta\vec{x}\|}{\|\vec{x}\|} \leq \underbrace{\|\mathbf{A}\| \|\mathbf{A}^{-1}\|}_{\text{ozn. } C_p} \frac{\|\Delta\vec{b}\|}{\|\vec{b}\|}$$

• Pro  $\Delta\mathbf{A} \neq \mathbf{0}$  :

$$\frac{\|\Delta\vec{x}\|}{\|\vec{x}\|} \leq C_p \frac{\frac{\|\Delta\mathbf{A}\|}{\|\mathbf{A}\|} + \frac{\|\Delta\vec{b}\|}{\|\vec{b}\|}}{1 - C_p \frac{\|\Delta\mathbf{A}\|}{\|\mathbf{A}\|}}$$

► Příklad: Dvě soustavy se stejnou maticí,  $C_p = \|\mathbf{A}\| \|\mathbf{A}^{-1}\| \approx 40\,002$ :

$$\begin{array}{l|l} \begin{array}{l} x + y = 2, \\ x + 1.0001y = 2.000\mathbf{1} \\ \text{Řešení: } \quad x = 1, \quad y = 1 \end{array} & \begin{array}{l} x + y = 2, \\ x + 1.0001y = 2.000\mathbf{2} \\ \text{Řešení: } \quad x = 0, \quad y = 2 \end{array} \end{array}$$

---

### Obecný význam podmíněnosti - skalární případ $y = f(x)$ :

$$\bullet \quad \hat{y} - y = f(x + \Delta x) - f(x) = f'(x) \Delta x + \frac{f''(x + \theta \Delta x)}{2!} (\Delta x)^2, \quad \theta \in (0, 1),$$

$$\Rightarrow \frac{\hat{y} - y}{y} = \frac{\hat{y} - y}{f(x)} \frac{x}{x} = \left( \frac{x f'(x)}{f(x)} \right) \frac{\Delta x}{x} + \mathcal{O}((\Delta x)^2)$$

$$\bullet \quad \text{Odtud definice } c(x) = \left| \frac{x f'(x)}{f(x)} \right|$$

► Příklad:  $f(x) = \ln(x), \quad c(x) = \left| \frac{x \frac{1}{x}}{\ln(x)} \right| = \left| \frac{1}{\ln(x)} \right|$

## Tridiagonální matice

---

$$\mathbf{T} = \begin{pmatrix} a_1 & b_1 & 0 & \dots & 0 & 0 & 0 \\ c_2 & a_2 & b_2 & \dots & 0 & 0 & 0 \\ 0 & c_3 & a_3 & \dots & 0 & 0 & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots & \vdots & \vdots \\ 0 & 0 & 0 & \dots & a_{n-2} & b_{n-2} & 0 \\ 0 & 0 & 0 & \dots & c_{n-1} & a_{n-1} & b_{n-1} \\ 0 & 0 & 0 & \dots & 0 & c_n & a_n \end{pmatrix}. \quad \text{Řešíme soustavu } \mathbf{T}\vec{x} = \vec{f}.$$

◇ Předpokládáme zpětný běh ve tvaru  $x_k = \mu_k x_{k+1} + \rho_k.$  (1)

◇  $j$ -tý řádek soustavy je  $c_j x_{j-1} + a_j x_j + b_j x_{j+1} = f_j.$  Po dosazení (1) máme

$$c_j \underbrace{(\mu_{j-1} x_j + \rho_{j-1})}_{x_{j-1}} + a_j x_j + b_j x_{j+1} = f_j \quad \text{neboli} \quad (c_j \mu_{j-1} + a_j) x_j + b_j x_{j+1} = f_j - c_j \rho_{j-1}$$

a tedy po vykrácení závorkou  $x_j = \frac{-b_j}{c_j \mu_{j-1} + a_j} x_{j+1} + \frac{f_j - c_j \rho_{j-1}}{c_j \mu_{j-1} + a_j}.$

◇ Po srovnání s předpokladem (1) dostáváme

$$\mu_j = \frac{-b_j}{c_j \mu_{j-1} + a_j}, \quad \rho_j = \frac{f_j - c_j \rho_{j-1}}{c_j \mu_{j-1} + a_j}. \quad (2)$$

$\Rightarrow$  Algoritmus: “přímý běh”  $\mu_1, \rho_1, \mu_2, \rho_2, \dots$  dle (2), “zpětný běh”  $x_n, x_{n-1}, \dots$  dle (1).

◇ Inicializace:  $c_1 = 0, \quad b_n = 0, \quad \mu_0, \rho_0$  a  $x_{n+1}$  libovolné.

**Příklad:**      **Numerické řešení ODR**       $y''(x) = \cos(\alpha x), \quad x \in \langle 0, 1 \rangle, \quad y(0) = y(1) = 0$

---

◇ POZN.: Uměli bychom vyřešit i analyticky:     $y(x) = \frac{-\cos(\alpha x) + (\cos(\alpha) - 1)x + 1}{\alpha^2}$

◇ Po diskretizaci ODR na  $n$  intervalů dostaneme systém

$$\begin{aligned} y_1 &= 0 \\ \frac{y_{i-1} - 2y_i + y_{i+1}}{\Delta x^2} &= \cos(\alpha x_i) \quad \text{pro } i = 2, \dots, n \\ y_{n+1} &= 0, \end{aligned}$$

kde  $\Delta x = \frac{1}{n}$  a tedy

$$\begin{aligned} y_1 &= 0 \\ -y_{i-1} + 2y_i - y_{i+1} &= -\frac{1}{n^2} \cos(\alpha x_i) \quad \text{pro } i = 2, \dots, n \\ y_{n+1} &= 0. \end{aligned}$$

Tuto soustavu lze zapsat maticově jako

$$\begin{pmatrix} 1 & 0 & 0 & 0 & \dots & 0 & 0 & 0 \\ -1 & 2 & -1 & 0 & \dots & 0 & 0 & 0 \\ 0 & -1 & 2 & -1 & \dots & 0 & 0 & 0 \\ 0 & 0 & -1 & 2 & \dots & 0 & 0 & 0 \\ \vdots & \vdots & \vdots & \vdots & \ddots & \vdots & \vdots & \vdots \\ 0 & 0 & 0 & 0 & \dots & 2 & -1 & 0 \\ 0 & 0 & 0 & 0 & \dots & -1 & 2 & -1 \\ 0 & 0 & 0 & 0 & \dots & 0 & 0 & 1 \end{pmatrix} \begin{pmatrix} y_1 \\ y_2 \\ y_3 \\ \vdots \\ y_{n-1} \\ y_n \\ y_{n+1} \end{pmatrix} = -\frac{1}{n^2} \begin{pmatrix} 0 \\ \cos(\alpha x_2) \\ \cos(\alpha x_3) \\ \vdots \\ \cos(\alpha x_{n-1}) \\ \cos(\alpha x_n) \\ 0 \end{pmatrix}$$

## Metoda SVD (Singular Value Decomposition)

---

- Matici  $\mathbf{A}$  rozložíme jako  $\mathbf{A} = \mathbf{U} \cdot \mathbf{W} \cdot \mathbf{V}^T$ , kde

$$\begin{array}{ll} \mathbf{A} \in \mathcal{R}^{m \times n}, & \mathbf{V} \in \mathcal{R}^{n \times n} \text{ je ortogonální,} \\ \mathbf{U} \in \mathcal{R}^{m \times n} \text{ je sloupcově ortogonální,} & \mathbf{W} \in \mathcal{R}^{n \times n} \text{ je diagonální.} \end{array}$$

►  $m > n$ : “overdetermined”

$$\begin{pmatrix} \mathbf{A} \end{pmatrix} = \begin{pmatrix} \mathbf{U} \end{pmatrix} \begin{pmatrix} w_1 & & \\ & \ddots & \\ & & w_n \end{pmatrix} \begin{pmatrix} \mathbf{V}^T \end{pmatrix}$$

- $m < n$ : “underdetermined”

$$\begin{pmatrix} \mathbf{A} \end{pmatrix} = \underbrace{\begin{pmatrix} \mathbf{U} \end{pmatrix}}_{m \text{ sloupců OG, ostatní nulové}} \begin{pmatrix} w_1 & & \\ & w_2 & \\ & & \ddots \\ & & & w_{n-1} \\ & & & & w_n \end{pmatrix} \begin{pmatrix} \mathbf{V}^T \end{pmatrix}$$

- Převédeme na druhou stranu  $\mathbf{A}\vec{x} = \vec{b} \quad \Leftrightarrow \quad \mathbf{U} \cdot \mathbf{W} \cdot \mathbf{V}^T \vec{x} = \vec{b}$

- Budeme tedy počítat

$$\vec{x} = \mathbf{V} \cdot \widetilde{\mathbf{W}} \cdot \mathbf{U}^T \vec{b}, \quad \text{kde} \quad \widetilde{\mathbf{W}} = \text{diag}(\tilde{w}_1, \dots, \tilde{w}_n), \quad \tilde{w} = \begin{cases} 0 & \text{pro } w_i \approx 0, \\ \frac{1}{w_i} & \text{jinak.} \end{cases}$$

## Řešení lineární soustavy pomocí gradientních metod


- Problém řešení  $\mathbf{A}\vec{x} = \vec{b}$  převedeme na úlohu minimalizace funkce více proměnných, např.

$$f(\vec{x}) = \frac{1}{2} \|\mathbf{A}\vec{x} - \vec{b}\|_{III} = \frac{1}{2} |\mathbf{A}\vec{x} - \vec{b}|^2 \quad (1)$$

- Obecný postup gradientních metod:

- Minimum funkce  $f(\vec{x})$  hledáme postupnou 1D minimalizací, vždy na přímce dané bodem  $\vec{x}^{(k)}$  a vektorem  $\vec{s}^{(k)}$ .
- Tedy v  $k$ -tém kroku hledáme na přímce  $\vec{x} = \vec{x}^{(k)} + \lambda \vec{s}^{(k)}$  bod, ve kterém je hodnota funkce  $f(\vec{x})$  minimální.
- Tento bod ozn.  $\vec{x}^{(k+1)}$  a zvolíme v něm nový směr  $\vec{s}^{(k+1)}$ .
- Nejjednodušší gradientní metody hledají vždy ve směru nejprudšího klesání, tedy (jednotkového) vektoru

$$\vec{s} = - \frac{\nabla f}{\|\nabla f\|_{III}}.$$



- Tedy konkrétně pro řešení lineárního systému  $\mathbf{A}\vec{x} = \vec{b}$  minimalizujeme funkci (1) tím, že v každém kroku hledáme  $\lambda$  takové, aby  $f(\vec{x} + \lambda \vec{s})$  bylo minimální. To znamená

$$\lambda = \frac{-\vec{s} \nabla f}{|\mathbf{A}\vec{s}|^2}, \quad \text{kde} \quad \nabla f(\vec{x}) = \mathbf{A}^T (\mathbf{A}\vec{x} - \vec{b})$$

a směr  $\vec{s}$  je dán konkrétní použitou gradientní metodou.

## Iterační metody: Řízená relaxace

---

- Pro jednoduchost uvažujme matici  $\mathbf{A}$ , která má na diagonále jedničky (tedy  $\forall i, a_{i,i} = 1$ )
- V  $k + 1$ . iteraci vynulujeme  $j$ -tou (maximální) složku rezidua  $|(\mathbf{A}\vec{x})_j - b_j|$  ( $j$ -tý řádek):

$$x_j^{(k+1)} = b_j - a_{j,1}x_1^{(k)} - \dots - a_{j,j-1}x_{j-1}^{(k)} - a_{j,j+1}x_{j+1}^{(k)} - \dots - a_{j,n}x_n^{(k)}$$

- Máme tedy iterační proces  $\vec{x}^{(k+1)} = \mathbf{B}_k \vec{x}^{(k)} + \vec{c}_k$ , kde

$$\mathbf{B}_k = \begin{pmatrix} 1 & & & & & & \\ & \ddots & & & & & \\ & & 1 & & & & \\ -a_{j,1} & \dots & -a_{j,j-1} & 0 & -a_{j,j+1} & \dots & -a_{j,n} \\ & & & 1 & & & \\ & & & & \ddots & & \\ & & & & & 1 & \end{pmatrix}, \quad \vec{c}_k = \begin{pmatrix} 0 \\ \vdots \\ 0 \\ b_j \\ 0 \\ \vdots \\ 0 \end{pmatrix}$$



## Konvergence stacionárních iteračních metod

---

- Po  $k$  iteracích s konstantní iterační maticí  $\mathbf{B}$  máme

$$(\vec{x}^{(k)} - \vec{x}) = \mathbf{B} (\vec{x}^{(k-1)} - \vec{x}) = \dots = \mathbf{B}^k (\vec{x}^{(0)} - \vec{x})$$

a tedy chceme, aby

$$\lim_{k \rightarrow \infty} \mathbf{B}^k = \mathbf{0}.$$

- Motivace: speciální případ  $\mathbf{B} = \mathbf{\Lambda} = \text{diag}(\lambda_1, \dots, \lambda_n)$ . Potom

$$\mathbf{\Lambda}^2 = \text{diag}(\lambda_1^2, \dots, \lambda_n^2)$$

$$\vdots$$

$$\mathbf{\Lambda}^k = \text{diag}(\lambda_1^k, \dots, \lambda_n^k).$$

Aby  $\lim_{k \rightarrow \infty} \mathbf{\Lambda}^k = \mathbf{0}$ , musí tedy  $\forall i, |\lambda_i| < 1$ .

- VĚTA: Iterační metoda konverguje právě když  $\rho(\mathbf{B}) = \max_i |\lambda_i| < 1$
- VĚTA: Pokud v některé normě platí  $\|\mathbf{B}\| < 1$ , potom iterační metoda konverguje

## Iterační metody: Prostá iterace

---

- Soustavu  $\mathbf{A}\vec{x} = \vec{b}$  formálně upravíme na

$$\vec{b} = \mathbf{A}\vec{x} - \vec{x} + \vec{x} = \mathbf{A}\vec{x} - \mathbf{I}\vec{x} + \vec{x} = (\mathbf{A} - \mathbf{I})\vec{x} + \vec{x}$$

a tedy

$$\underbrace{\vec{x}}_{\text{volíme } \vec{x}^{(k+1)}} = (\mathbf{I} - \mathbf{A}) \underbrace{\vec{x}}_{\text{volíme } \vec{x}^{(k)}} + \vec{b},$$

což odpovídá předpisu iterační metody s maticí  $(\mathbf{I} - \mathbf{A})$ .

- U metody prosté iterace lze přesnost  $k$ -té iterace odhadnout jako

$$\|\vec{x}^{(k)} - \vec{x}\| \leq \|\mathbf{B}\|^k \left( \|\vec{x}^{(0)}\| + \frac{\|\vec{b}\|}{1 - \|\mathbf{B}\|} \right),$$

kde  $\mathbf{B} = \mathbf{I} - \mathbf{A}$ .

## Iterační metody: Jacobiho metoda

---

- Soustavu upravíme na

$$\begin{aligned}\vec{b} = \mathbf{A}\vec{x} &= \mathbf{L}\vec{x} + \mathbf{D}\vec{x} + \mathbf{R}\vec{x} \\ \Rightarrow \mathbf{D}\vec{x} &= \vec{b} - (\mathbf{L} + \mathbf{R})\vec{x} \\ \Rightarrow \vec{x} &= \mathbf{D}^{-1}\vec{b} - \mathbf{D}^{-1}(\mathbf{L} + \mathbf{R})\vec{x}\end{aligned}$$

- Budeme tedy iterovat  $\boxed{\vec{x}^{(k+1)} = -\mathbf{D}^{-1}(\mathbf{L} + \mathbf{R})\vec{x}^{(k)} + \mathbf{D}^{-1}\vec{b}}$ , neboli po složkách

$$x_j^{(k+1)} = -\frac{a_{j,1}}{a_{j,j}}x_1^{(k)} - \dots - \frac{a_{j,j-1}}{a_{j,j}}x_{j-1}^{(k)} - \frac{a_{j,j+1}}{a_{j,j}}x_{j+1}^{(k)} - \dots - \frac{a_{j,n}}{a_{j,j}}x_n^{(k)} + \frac{b_j}{a_{j,j}}.$$

VĚTA:  $\mathbf{A}$  je diagonálně dominantní  $\Rightarrow$  Jacobiho metoda konverguje.

DŮKAZ: v řádkové či sloupcové normě

$$\begin{aligned}\|\mathbf{D}^{-1}(\mathbf{L} + \mathbf{R})\| &= \max_i \sum_{j=1}^n \left| (\mathbf{D}^{-1}(\mathbf{L} + \mathbf{R}))_{i,j} \right| = \\ &= \max_i \frac{1}{|a_{i,i}|} \sum_{j=1, j \neq i}^n |a_{i,j}| \stackrel{\text{diag. dom.}}{<} \\ &\stackrel{\text{diag. dom.}}{<} \max_i \frac{|a_{i,i}|}{|a_{i,i}|} = 1.\end{aligned}$$

## Iterační metody: Gauss-Seidelova metoda

---

- $k + 1$ . iterace,  $j$ -tý řádek:

$$x_j^{(k+1)} = -\frac{a_{j,1}}{a_{j,j}}x_1^{\boxed{(k+1)}} - \dots - \frac{a_{j,j-1}}{a_{j,j}}x_{j-1}^{\boxed{(k+1)}} - \frac{a_{j,j+1}}{a_{j,j}}x_{j+1}^{(k)} - \dots - \frac{a_{j,n}}{a_{j,j}}x_n^{(k)} + \frac{b_j}{a_{j,j}},$$

neboli v maticovém zápisu

$$\vec{x}^{(k+1)} = -(\mathbf{L} + \mathbf{D})^{-1} \mathbf{R} \vec{x}^{(k)} + (\mathbf{L} + \mathbf{D})^{-1} \vec{b}.$$

---

---

## Iterační metody: Superrelaxační metoda

---

- Jako Gauss-Seidelova, ale s urychlenou konvergencí:

$$\vec{x}^{(k+1),\text{SR}} = \vec{x}^{(k)} + \omega [\Delta \vec{x}^{(k)}]_{\text{GS}}, \quad \text{kde} \quad [\Delta \vec{x}^{(k)}]_{\text{GS}} = \vec{x}^{(k+1),\text{GS}} - \vec{x}^{(k)}$$

- Optimální relaxační parametr

$$\omega_{\text{opt}} = \frac{2}{1 + \sqrt{1 - \rho^2(\mathbf{B})}} = \frac{2}{1 + \sqrt{1 - \rho^2((\mathbf{L} + \mathbf{D})^{-1} \mathbf{R})}}$$

## Hledání vlastních čísel: pojmy, definice, vlastnosti matic

---

- Vlastní číslo, vlastní vektor
- Úplný vs. částečný problém vlastních čísel
- Charakteristický polynom matice, násobnost vlastního čísla
- Defektní matice
- Symetrická matice
- Podobné matice
- Normální matice
- Trojúhelníková matice

– Podobné matice mají stejná všechna vlastní čísla

$$\begin{aligned}\det(\mathbf{P}^{-1}\mathbf{A}\mathbf{P} - \lambda\mathbf{I}) &= \det(\mathbf{P}^{-1}\mathbf{A}\mathbf{P} - \lambda\mathbf{P}^{-1}\mathbf{I}\mathbf{P}) = \det(\mathbf{P}^{-1}(\mathbf{A} - \lambda\mathbf{I})\mathbf{P}) = \\ &= \det(\mathbf{P}^{-1}) \det(\mathbf{A} - \lambda\mathbf{I}) \det(\mathbf{P}) = \det(\mathbf{A} - \lambda\mathbf{I})\end{aligned}$$

– Matice v Jordanově normálním (kanonickém) tvaru

$$\mathbf{J} = \begin{pmatrix} \mathbf{J}_1 & 0 & \dots & 0 \\ 0 & \mathbf{J}_2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \mathbf{J}_s \end{pmatrix} \quad \text{kde} \quad \mathbf{J}_i = \begin{pmatrix} \lambda_i & 0 & \dots & 0 & 0 \\ 1 & \lambda_i & \dots & 0 & 0 \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ 0 & 0 & \dots & \lambda_i & 0 \\ 0 & 0 & \dots & 1 & \lambda_i \end{pmatrix}$$

## Hledání vlastních čísel: Jacobiho transformace

---

Z celé matice

$$\mathbf{A}^{(k)} = \begin{pmatrix} a_{1,1}^{(k)} & \dots & \dots & \dots & \dots & \dots & a_{1,n}^{(k)} \\ \vdots & \ddots & & & & & \vdots \\ \vdots & & a_{p,p}^{(k)} & \dots & a_{p,q}^{(k)} & & \vdots \\ \vdots & & \vdots & \ddots & \vdots & & \vdots \\ \vdots & & a_{p,q}^{(k)} & \dots & a_{q,q}^{(k)} & & \vdots \\ \vdots & & & & & \ddots & \vdots \\ a_{n,1}^{(k)} & \dots & \dots & \dots & \dots & \dots & a_{n,n}^{(k)} \end{pmatrix}$$

se soustředíme na  
submatici  $2 \times 2$  tvořenou

$$\mathcal{A}^{(k)} = \begin{pmatrix} a_{p,p}^{(k)} & a_{p,q}^{(k)} \\ a_{p,q}^{(k)} & a_{q,q}^{(k)} \end{pmatrix}$$

a chceme ji diagonalizovat.

- Otočíme osy o vhodný úhel  $\varphi^{(k)}$ , neboli vynásobíme

$$\mathcal{A}^{(k+1)} = \mathcal{M}^T \mathcal{A}^{(k)} \mathcal{M} = \begin{pmatrix} \cos \varphi^{(k)} & \sin \varphi^{(k)} \\ -\sin \varphi^{(k)} & \cos \varphi^{(k)} \end{pmatrix} \begin{pmatrix} a_{p,p}^{(k)} & a_{p,q}^{(k)} \\ a_{p,q}^{(k)} & a_{q,q}^{(k)} \end{pmatrix} \begin{pmatrix} \cos \varphi^{(k)} & -\sin \varphi^{(k)} \\ \sin \varphi^{(k)} & \cos \varphi^{(k)} \end{pmatrix}.$$

- Nová hodnota prvku  $a_{p,q}^{(k+1)}$  je  $a_{p,q}^{(k+1)} = (\cos^2 \varphi^{(k)} - \sin^2 \varphi^{(k)}) a_{p,q}^{(k)} - \cos \varphi^{(k)} \sin \varphi^{(k)} (a_{p,p}^{(k)} - a_{q,q}^{(k)})$ .
- Aby  $a_{p,q}^{(k+1)} = 0$ , musí být pravá strana rovna nule:

$$0 \stackrel{!}{=} \cos 2\varphi^{(k)} a_{p,q}^{(k)} - \frac{1}{2} \sin 2\varphi^{(k)} (a_{p,p}^{(k)} - a_{q,q}^{(k)}) \quad \text{neboli} \quad \operatorname{tg} 2\varphi^{(k)} = \frac{2 a_{p,q}^{(k)}}{a_{p,p}^{(k)} - a_{q,q}^{(k)}}.$$

---

*Jacobiho transformace (pokračování)*

---

- V  $k + 1$ . kroku Jacobiho transformace tedy máme submatici

$$\mathcal{A}^{(k)} = \begin{pmatrix} a_{p,p}^{(k)} & a_{p,q}^{(k)} \\ a_{p,q}^{(k)} & a_{q,q}^{(k)} \end{pmatrix} \quad \text{transformovánu na} \quad \mathcal{A}^{(k+1)} = \begin{pmatrix} a_{p,p}^{(k+1)} & 0 \\ 0 & a_{q,q}^{(k+1)} \end{pmatrix}.$$

- Transformace celé matice je tedy

$$\mathbf{A}^{(k+1)} = \mathbf{M}_{\mathbf{p},\mathbf{q}}^T \mathbf{A}^{(k)} \mathbf{M}_{\mathbf{p},\mathbf{q}},$$

kde  $\mathbf{M}_{\mathbf{p},\mathbf{q}}$  je tzv. *Givensova rotační matice*

$$\mathbf{M}_{\mathbf{p},\mathbf{q}} = \begin{pmatrix} 1 & & & & & & 0 \\ & \ddots & & & & & \\ & & \cos \varphi^{(k)} & & & & \\ & & & \ddots & & & \\ & & & & 1 & & \\ & & & & & \ddots & \\ & & \sin \varphi^{(k)} & & & \cos \varphi^{(k)} & \\ & & & & & & \ddots \\ 0 & & & & & & & 1 \end{pmatrix}.$$

## Jacobiho transformace - Důkaz konvergence

---

- Označíme součet čtverců mimodiag. prvků jako 
$$t(\mathbf{A}) = \sum_{i,j; j \neq i}^n a_{i,j}^2 = \sum_{i=1}^n \sum_{j=1; j \neq i}^n a_{i,j}^2.$$
- V  $k$ -té iteraci jsme vynulovali prvek  $a_{p,q} \Rightarrow$  
$$\underbrace{\sum_{i,j; j \neq i}^n (a_{i,j}^{(k)})^2}_{t(\mathbf{A}^{(k)})} = \underbrace{\sum_{i,j; j \neq i}^n (a_{i,j}^{(k-1)})^2}_{t(\mathbf{A}^{(k-1)})} - 2a_{p,q}^2. \quad (1)$$

- $a_{p,q}$  byl pivot mezi mimodiag. prvky  $\mathbf{A}^{(k-1)} \Rightarrow \forall \{(i,j), j \neq i\}, \quad (a_{i,j}^{(k-1)})^2 \leq a_{p,q}^2.$

- Protože mimodiagonálních prvků je  $n(n-1)$ , platí

$$\underbrace{\sum_{i,j; j \neq i}^n (a_{i,j}^{(k-1)})^2}_{t(\mathbf{A}^{(k-1)})} \leq n(n-1) a_{p,q}^2 \iff a_{p,q}^2 \geq \frac{t(\mathbf{A}^{(k-1)})}{n(n-1)}. \quad (2)$$

- Dosadíme (2) do (1) a máme

$$\begin{aligned} t(\mathbf{A}^{(k)}) &= t(\mathbf{A}^{(k-1)}) - 2a_{p,q}^2 \leq t(\mathbf{A}^{(k-1)}) - 2 \frac{t(\mathbf{A}^{(k-1)})}{n(n-1)} = \left(1 - \frac{2}{n(n-1)}\right) t(\mathbf{A}^{(k-1)}) \\ &\leq \left(1 - \frac{2}{n(n-1)}\right)^2 t(\mathbf{A}^{(k-2)}) \leq \left(1 - \frac{2}{n(n-1)}\right)^k t(\mathbf{A}^{(0)}), \end{aligned}$$

kde  $\mathbf{A}^{(0)} = \mathbf{A}$  je původní matice.

Posloupnost jsme shora odhadli geometrickou posloupností s kvocienem  $< 1$ . □



## Částečný problém vlastních čísel

---

$$\mathbf{P} = \begin{pmatrix} u_1^1 & 0 & 0 & \dots & 0 \\ u_2^1 & 1 & 0 & \dots & 0 \\ u_3^1 & 0 & 1 & \dots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ u_n^1 & 0 & 0 & \dots & 1 \end{pmatrix}, \quad \mathbf{P}^{-1}\mathbf{A}\mathbf{P} = \begin{pmatrix} \lambda_1 & \vec{q}^T \\ \vec{0} & \mathbf{B} \end{pmatrix},$$

Jak to, že to funguje? Např. pro matici  $\mathbf{A}^{3 \times 3}$  s vlastními vektory  $\vec{v}_{1,2,3}$ :

- Libovolný vektor můžeme zapsat jako  $\vec{x} = \alpha_1 \vec{v}_1 + \alpha_2 \vec{v}_2 + \alpha_3 \vec{v}_3$ .
- Z linearity plyne, že
 
$$\begin{aligned} \mathbf{A}\vec{x} &= \mathbf{A}(\alpha_1 \vec{v}_1 + \alpha_2 \vec{v}_2 + \alpha_3 \vec{v}_3) = \\ &= \alpha_1 \mathbf{A} \vec{v}_1 + \alpha_2 \mathbf{A} \vec{v}_2 + \alpha_3 \mathbf{A} \vec{v}_3 = \\ &= \alpha_1 \lambda_1 \vec{v}_1 + \alpha_2 \lambda_2 \vec{v}_2 + \alpha_3 \lambda_3 \vec{v}_3. \end{aligned}$$
- Po dalším vynásobení:  $\mathbf{A}\mathbf{A}\vec{x} = \alpha_1 \lambda_1^2 \vec{v}_1 + \alpha_2 \lambda_2^2 \vec{v}_2 + \alpha_3 \lambda_3^2 \vec{v}_3$ , atd.,  
tedy po  $n$  vynásobení:  $\mathbf{A}^n \vec{x} = \alpha_1 \lambda_1^n \vec{v}_1 + \alpha_2 \lambda_2^n \vec{v}_2 + \alpha_3 \lambda_3^n \vec{v}_3$ .
- BÚNO předpokládáme, že  $|\lambda_1| > |\lambda_2| > |\lambda_3|$

$$\Rightarrow \text{pro velká } n \text{ platí } |\lambda_1|^n \gg |\lambda_2|^n \gg |\lambda_3|^n$$

$$\Rightarrow \mathbf{A}^n \vec{x} \approx \alpha_1 \lambda_1^n \vec{v}_1. \quad \square$$